

中医古籍指代关系语料库的构建与指代消解方法研究 *

■ 张婷婷^{1,2} 王亚强³ 梁海峰³ 闵新⁴ 杨静² 温川飙⁴

¹ 成都中医药大学国学院 成都 610075

² 四川省哲学社会科学重点实验室“出土医学文献文物保护研究数字重点实验室” 成都 610075

³ 成都信息工程大学软件工程学院 成都 610225

⁴ 成都中医药大学智能医学学院 成都 610075

摘要: [目的/意义] 中医古籍指代消解是完整获取古籍知识、构建古籍知识图谱的关键步骤之一。然而, 由于目前缺少公开发布的中医古籍指代关系语料库, 导致中医古籍的指代消解研究很难开展。基于此, 以中风和妊娠腹痛的古籍文献为例, 构建指代关系语料库, 并进行指代消解方法实验, 为后续研究提供参考。[方法/过程] 从《中华医典》选取中风和妊娠腹痛的古籍文献记录, 定义并标注三类指代词、两类先行词和一种指代关系, 人工标注构建语料库并进行质量评估。在实验阶段, 指代消解被分为指称识别和指代关系预测两个子任务, 实验组选用基于预训练模型 BERT 的指代消解模型 BERT-BiLSTM-CRF, 并与 BiLSTM-CRF 和 CRF 模型进行对比。[结果/结论] 语料库标注一致性平均值达 0.87, 提示语料库质量良好; BERT-BiLSTM-CRF 模型在指代消解任务上性能明显优于另外两种模型。总体来看, 利用深度学习技术来进行中医古籍的指代消解是可行的, 且利用预训练模型 BERT 可以更好地提高模型性能。未来的研究需要进一步增加语料库的规模, 训练大模型来助力中医古籍知识发现的研究。

关键词: 中医古籍 语料库 指代关系 指代消解

分类号: TP391.1 G202

CSTR: 32305.14.CN11-1541.2025.14.010

DOI: 10.13266/j.issn.0252-3116.2025.14.010

引用本文: 张婷婷, 王亚强, 梁海峰, 等. 中医古籍指代关系语料库的构建与指代消解方法研究 [J]. 图书情报工作, 2025, 69(14): 113-120. (Citation: Zhang Tingting, Wang Yaqiang, Liang Haifeng, et al. Research on Corpus Construction and Reference Resolution Methods of Ancient Literature on Traditional Chinese Medicine[J]. Library and Information Service, 2025, 69(14): 113-120.)

1 引言 / Introduction

中医古籍是中华民族瑰宝, 历经几千年的传承和发展, 积累了大量的中医文化和临床经验的珍贵文献资料, 其具有重要的研究价值。近年来, 随着古籍数字化进程的推进, 传统的利用方式难以满足大规模古籍知识的获取与利用, 中医古籍数字化面临新的机遇与挑战。与此同时, 随着自然语言处理技术的迅猛发展, 海量中医古代文献的知识表示和知识发现成为可能^[1], 借助实体识别、语义关系抽取等关键技

术, 能够将非结构化中医古籍文本转化为结构化的知识库, 从而为下一步的知识发现研究提供有力支撑。目前, 中医领域的信息抽取主要采用基于规则、传统机器学习和深度学习等方法^[2], 对病名、症状、方剂、证候等实体及关系进行抽取和验证^[3-7]。然而, 古代文献中除了常见的命名实体及其语义关系以外, 还存在随处可见的指代现象^[8]。语言学中把采用简称或代称等指代词来代替上文中出现的实体或实体组合的现象称为指代, 是人类语言的一大独特性^[9]。指代能够避免同一词语重复出现所造成的语句臃肿、

* 本文系成都中医药大学“杏林学者”学科人才提升计划项目“基于语义分析的中医古籍文献知识图谱的构建与应用研究——以中风病为例”(项目编号: BSH2020031) 和中国出土医学文献与文物研究中心委托专项“医学出土文物数字化挖掘与分析”(项目编号: ctwx2424) 研究成果之一。

作者简介: 张婷婷, 讲师, 博士; 王亚强, 副教授, 博士; 梁海峰, 硕士研究生; 闵新, 讲师, 博士; 杨静, 教授, 硕士; 温川飙, 研究员, 硕士, 通信作者, E-mail: wcb@cdutcm.edu.cn。

收稿日期: 2024-08-02 **修回日期:** 2024-12-07 **本文起止页码:** 113-120

版权所有 ©《图书情报工作》杂志社有限公司, 未经许可不得转载 (Copyrights © LIS Press Co., Ltd. Reproduction is prohibited without permission)

赘述等问题；但同时也可能因为这种省略造成指代不明等问题，导致信息抽取不能完整地获取古籍知识，影响对全文的理解，因此还需要进行指代消解。如图 1 所示，古代医家常使用“之”“此”等指代词来指代前面已经出现过的内容，该条文共使用 6 次

“之”字作为代词。通过分析上下文可知，“按之不足，举之有余”中两个“之”字分别指代“阴脉”和“阳脉”，因此中风的脉象是“重按阴脉不足，轻按阳脉有余”。可见，中医古籍需要理清指代关系才能获得完整的语义。




图 1 中医古籍文献指代关系标注示例

Figure 1 Example of referential relations in TCM literature

指代消解是将代表同一实体的不同指称划分到一个等价集合（指代链）的过程^[10]。指代消解能够有效解决文本当中指代不明的问题，是中医古籍的一项基础性研究，在全文理解、机器翻译、自动问答、信息抽取等任务中起重要作用^[11]。近 20 年，现代汉语领域已经开发了很多语料库以支撑指代消解的研究^[12-17]，并取得了丰硕的技术成果^[18-19]，如基于长短期记忆网络^[20]、异构图模型^[21]、双向长短期记忆网络和条件随机场^[22]以及基于预训练模型 BERT (bidirectional encoder representations from transformers)^[23-24]的指代消解方法。其中值得关注的是 BERT 模型将自注意力机制融合进双向 Transformer 编码器，使关于语句上下文的语义信息能够被更深层次的从两个方向同时获取，得到更强的语义特征，继而提高模型性能。总而言之，在语料库的支撑下，公共汉语的指代消解研究有了较大进展。

在中医古籍研究领域，指代消解是深度解析古籍知识、知识图谱构建的重要步骤，目的是提高数据集的完整性和一致性^[25,26]。中医具有次语言的特点^[27]，存在大量的领域表达习惯^[28,29]，不同朝代的医家具有不同的社会文化背景，写作习惯存在一定差异^[8]，因而指代类型和特点与公共汉语有许多不同^[29]。例如，中医古籍中的代词除了一词多义，还具有单复数形式相同、无性别属性等特点，导致公共汉语的指代特征^[30]不能都适用于中医古籍的指代特征提取。目前中医领域指代消解相关研究较少，

本研究未见文献报道有公开发布的中医古籍文献指代关系语料库，导致古籍指代消解方法研究很难充分开展。基于此，本研究整理并分析语料库中指代词和先行词（指代词所指代的内容）的类型及特点，构建了中医古籍文献指代关系语料库，进行了指代消解方法实验，提出了基于预训练模型 BERT 的指代消解方法，以期为未来中医古籍指代消解研究提供方法学的参考，为中医古籍知识发现等研究提供新思路。

2 语料库的构建 /Corpus construction


2.1 数据源

本研究从《中华医典》^[31]中摘录中风和妊娠腹痛相关的古籍文献记录，共 8 285 条记录，455 299 字。一条记录是指描述疾病的字面连续且语义相关的句子或段落。本研究纳入的数据在作者、年代、内容上具有多样性的特点。

2.2 标签及定义

基于自然语言处理的基础知识^[32]，本研究定义并标注了 3 类指代词，两类先行词和一种指代关系（见表 1）。本研究针对的是有显性指代词的指代现象，零指代不在本次研究的范畴。考虑到疑问代词和其指代内容之间存在真实的联系，本研究将疑问代词和对应回答定义为一种特殊的指代形式。如此设置是因为在中医古籍中，作者已经知道了问题的答案，疑问代词的使用主要用以引出回答的内容并表示强调。

表 1 指代词、先行词和指代关系的定义与示例
Table 1 Definition and examples of pronouns, antecedents, and referential relations

标注类	标签	定义	示例
指代词 (p)	人物指代词	指代人物的指代词	因暮年老人中风, 请金(p)诊治
	事物指代词	指代事物的指代词	妇人怀孕, 腹中疼痛(a), 当归芍药散主之(p)
	疑问代词	构成问答的疑问代词	先热后寒者何(p)也?
先行词 (a)	人物	被人称指代词所指代的人称词或短语	至刘河间(a)出世……其(p)论专主于火
	事物	被事物指代词和疑问代词指代的字、短语或句子	芍药(a)酸敛, 其(p)性内行下走
关系	指代关系	指示词和指代物之间构成的关系	

2.3 数据标注和评价

在数据标注方法上, 本研究采用团队前期发表的语料库构建方法^[33], 标注流程见图 2, 即通过起草标注指南、标注训练和一致性评价、全面标注来进行。具有中医执业医师资格的 3 名标注者经过 4 轮标注训练和 1 轮全面标注, 完成了古籍指代关系数据集的构建。最后, 本研究使用 Cohen's kappa^[34] 来检测有两个或两个以上的指定标注者的一致性^[35, 36]。结果显示, 最后一轮全面标注的 IAA (inter-annotator agreement) 平均值达到了 0.87, 说明该语料库质量良好。

3 标注结果和分析 / Annotation results and analyses

3.1 标注统计结果

本研究共标注了 5 231 条指代关系, 指称 (包括指代词和先行词) 类型及数量 (见图 3)。可以看出, 先行词的重复率非常低, 说明古籍中先行词的语言描述差异性较大。本研究采用的统计方法是基于字符,




图 2 标注流程
Figure 2 Annotation workflow

而非基于语义, 因此很多同义词被标记为不同的先行词。例如, “孕妇腹疼” “妊娠腹痛” “胎痛” 都表达了妊娠期间腹痛的症状, 但均被统计为不同的先行词。另外, 我们注意到指代词、先行词以及指代关系的标注计数之间存在不一致性, 这是由于部分指代词在原文中没有先行词, 多个指代词指向同一个先行词或者一个指代词指代多个先行词。

3.2 中医古籍中指代的类型和分析

对于有指代词的指代, 根据指代词的不同可分为 3 个大类: 人物指代, 事物指代以及疑问指代 (见表 2)。

3.2.1 人物指代

人物指代词主要包括人称代词和有定描述。在中医古籍中, 人称代词主要包括第一人称代词 (如 “余” “吾”)、第三人称代词 (如 “其” “之” “彼”)、不定代词 (如 “或”)。需要注意的是, 第二人称代词几乎没有被使用到, 是由于中医古代文献主要是记叙文风格。古人喜欢用 “... 者” 来表达一类病人 (如




图 3 不同指称的标注类别和数量
Figure 3 Annotation classes and counts of pronouns and antecedents

表 2 指代词的分类和定义
Table 2 Classification and definition of pronouns

指代词	类型细分	解释和定义	示例
人物指代词 (p)	人称代词	指代人物的代词	问金 (p) 曰, 何也?
	有定描述	指代特定人物的名词	而知此妇人 (p) 本脏属虚寒者
事物指代词 (p)	物主代词	用以指代事物的代词	中风无汗恶寒 (a), 麻黄续命汤主之 (p)
	有定描述	指代特定事物的名词	小续命汤 (a) ……脚弱服此方 (p)
	不定描述	指代非特定事物的名词	盖此等药 (a) 甚多
	特殊用词	特殊的中医指代词, 如方位词、表达借喻的名词	上部 (p) 有脉, 下部 (p) 无脉, 郁土 (p) 虚
疑问代词 (p)		指代具体内容的疑问词	中风之病形何 (p) 如?

“中风者”), 占人物先行词的 59.3%。另外, 在中医古籍中, 尽管被指代的先行词没有显性表达, 但均可被读者推断和理解, 例如代词“余”指代作者本人。

3.2.2 事物指代

古代医家喜欢使用指代词使句子精炼和简洁, 特别是对于一些文字较多的表达 (如方剂组成、症状群等)。事物指代词在古代文献中最常见, 包括指示代词 (如“此”“之”)、有定描述 (如“此方”)、不定描述 (如“此等药”) 以及特殊的事物指代词 (如“木”“土”)。此类指代关系体现了中医古籍中部分指代表达的习惯: ①有定描述在中医古籍中也非常常见, 如古代医家喜欢使用“此方”来指代特定的方剂; ②部分由方位词组成的名词短语被标注为指代词, 如名词性指代词“上件药”“前法”和“后方”, 方位词 (“上”“前”“后”) 有助于识别先行词的位置, 而后缀词 (“药”“法”“方”) 限制了先行

词内容; ③数量词有时被用来形成一个有定描述指代词, 如“中风最宜辨团 (a) 脱 (b) 二症 (p)”, 有定名词短语“二症”指代 (a) 和 (b); ④特殊指代词具有显著的中医语言表达特色, 如古代医家会用五行属性来代替脏腑的表达。

3.2.3 疑问指代

在中医古籍中, 疑问代词的使用主要有两种情况: ①设计问题: 作者故意设计了一个疑问, 并随即给出回答, 目的是为了强调回答的内容。例如: “何 (p) 以见之? 曰以今难产者多 (a) 也”。②情景记录: 作者记录了看诊的对话过程, 例如, “问余曰, 何 (p) 也? 余曰…”。也是为了强调回答的内容。

3.3 中医古籍中指代现象广布, 代词常一词多义且先行词类型众多

在中医古籍中, 先行词的类型非常多, 涵盖了大多数中医领域的概念、类型和示例 (见表 3)。以此

表 3 先行词的类型和示例
Table 3 Types and examples of antecedents

指代词类型	先行词的类型	举例
人物先行词 (a)	人名	至刘河间 (a) 出世……其 (p) 论专主于火
	一类人	妇人 (a) 欲生, 其 (p) 脉离经
事物先行词 (a)	特定人物	中风者 (a), 皆由元气不足, 而邪凑之 (p)
	方剂组成	地黄当归汤治胎痛, 当归 (一两), 熟地黄 (二两) (a), 上 (p) 为末
	方剂名	大秦芩汤 (a), 治中风手足并不能运动……此方 (p) 主之
	中药名	芍药 (a) 酸敛, 其 (p) 性内行下走
	病名	中风 (a) 之症治须思, 审其 (p) 所中善治之
	症状	中风无汗恶寒 (a), 麻黄续命汤主之 (p)
	脉象	血不足以充之, 故细 (a) 也, 一见此脉 (p), 便是营血已伤
	治法	及其久也, 即当活血 (a), 此 (p) 万古不易之理
	病机	然血虚 (a) 居多, 用熟地三钱, 当归一钱, 煎汤治之 (p)
	剂量	风寒盛者十四壮 (a) 为率, 或二三次报之 (p), 但不可过多
	经络	手三阳之经 (a), 结于颌颊, 上夹于口, 风邪乘之 (p) 则筋挛
	穴位	神阙 (a), 凡卒中者此穴 (p) 最佳
	脏腑	令脏脏 (a) 各司其 (p) 职
	其他	邪风之至, 疾如风雨 (a), 言邪之迅速如此 (p)
疑问代词的对应结论 (a)	回答“为什么”	人面独能耐寒者, 何 (p) 也? 诸阳脉皆上头, 故令面耐寒 (a) 也
	回答“什么”	何 (p) 为五邪? 然, 有中风 (a), 有伤寒 (a), 有饮食劳倦 (a), 有伤寒 (a), 有中湿 (a), 此 (p) 之谓五邪
	回答“如何”	何 (p) 以知中风得之? 然其色当赤 (a)

可知，古代医家在书写时广泛使用指代表达，因此想要机器能读懂字面含义就需要对指代进行消解，而深入解读则还需要进一步为机器赋予中医基础知识。

就代词而言，中医古籍中最常用的指代词是“之”“其”“此”和“何”。大多数出现频次较高的代词都是多义词，被广泛应用于不同的上下文中。例如，“何”“之”和“其”可以同时指人和非人的先行词。此外，这些高频代词可以与其他词相结合，形成新的有定描述名词，如“此方”“其病”等。因此，识别单一的代词和由代词组成的名词性指代词可能会存在争议。

4 指代消解方法实验/Reference resolution methods experiments

4.1 指代消解方法

本研究将指代消解分成两个子任务：指称识别和指代关系的抽取。首先，从文本语句中识别出候选的文本片段，该过程和命名实体识别处理过程相同，是一个序列标注任务；然后，指代消解模块判断指代词和先行词是否具有指代关系，该任务是二分类任务，只有“有指代关系”和“无指代关系”两种情况。在方法上，本研究提出用 BERT-BiLSTM-CRF（Bidirectional Encoder Representations from Transformers-Bi-directional Long Short-Term Memory-Conditional Random Field）的深度学习模型进行实验。首先将古籍数据转换成字符级别的序列，然后利用 BERT 对每个词语进行编码，输出每个词语的上下文相关的向量表示。这些向量包含了词语的语义以及上下文信息。然后，将预训练的古籍词向量输入 BiLSTM 中提取更高级的上下文语义特征。最后，将 BiLSTM 输出的特征序列输入 CRF 中，CRF 会根据学习到的标签转移概率和特征函数，计算出每个位置上不同标签的概率分布，并通过解码找到全局最优的标签序列作为最佳标注结果。本

研究使用指代关系语料库在 BERT-BiLSTM-CRF 与另外两种常用模型（BiLSTM-CRF 和 CRF）进行了对照实验，实验结果表明基于 BERT 的模型在中医古籍指代消解任务中性能更优。本研究的数据集以 8:1:1 的比例划分为训练集、验证集和测试集。在评价方法上，采用分类任务中的精确率（precision）、召回率（recall）和 F1 值作为指称词识别的评价指标，采用准确率（accuracy）作为指代关系识别的评价指标。

4.2 实验结果与分析

指称识别和指代关系识别的实验结果见表 4。就内容而言，3 个指代消解模型在妊娠腹痛数据的表现均较在中风数据上的表现更好。可见，在中医古籍中，不同病种之间的语言表达存在些许差异。另外，由于本次研究中，中风的数据量多于妊娠腹痛，模型训练的效果更好可能与数据集更大有关。就方法而言，与设计了特征规则的机器学习模型 CRF 相比，深度学习模型 BiLSTM-CRF 通过学习目标指称的语义向量进行指称识别任务，因此丰富的指称数量能提高深度学习模型的学习能力，数据集中数量分布较多的指称，则模型学习更加充分，识别效果更好。然而，中医古籍中指称存在数量严重分布不均匀的情况（见图 2），导致深度学习模型 BiLSTM-CRF 与 CRF 模型相比，在序列标注任务上没有表现出性能优势。在此基础上，本研究进一步实验了 BERT-BiLSTM-CRF 模型。与 BiLSTM-CRF 相比，BERT-BiLSTM-CRF 将 Embedding 层换成了 BERT，可以将大量语义信息迁移过来。结果显示，BERT-BiLSTM-CRF 在中医古籍的指代消解任务上可以在数据分布不均匀的情况下，获得较另外两个模型更加优越的性能。作为自然语言处理的大规模预训练模型，BERT 可以捕捉上下文关系，在已经训练好的模型的基础上进行再训练 and 微调，继而提高模型性能。今后的研究如果能够增大数据规模，相信预训练模型 BERT 将会有更加出色的表现。

表 4 实验结果
Table 4 Experiment results

模型	指称识别						指代关系识别	
	妊娠腹痛			中风			妊娠腹痛	中风
	P	R	F1	P	R	F1	Accuracy/%	
CRF	0.618	0.497	0.527	0.594	0.458	0.509	48	41
BiLSTM-CRF	0.521	0.470	0.470	0.471	0.296	0.334	38	32
BERT-BiLSTM-CRF	0.714	0.535	0.612	0.617	0.535	0.542	55	43

5 结语 /Conclusions

中医古籍是中国文化传承和发展的重要部分,如何基于先进的计算机技术对古籍文本进行重构与挖掘,让古籍知识得到充分利用,推动中医文化的传承和发展,是未来中医古籍研究的新方向。然而,由于中医古籍来源众多、年代久远、晦涩难懂,一词多义、语义歧义现象常见,且中医古文中往往代词单复数同形、无性别属性,导致古籍中指代关系复杂、指代特征不显著,因此中医古籍的指代消解研究面临着巨大挑战。本研究构建了中医古籍指代关系语料库,整理和分析了语料库中指代词和先行词的类型,并在此基础上进行了指代消解方法实验。结果显示,BERT-BiLSTM-CRF在中医古籍的指代消解任务上可以在数据分布不均匀的情况下,具有较CRF和BiLSTM-CRF模型更好的性能。总而言之,中医古籍文献的指代消解具有较大难度,仍面临巨大挑战,但结合预训练语言模型是一条可行之路。

本研究仍存在一些不足之处。首先,语料库中有很多重复率很低的实体和关系,提示语料库规模是不足的,未来还需要囊括更多病种的文献数据,进一步扩大语料库的规模,继而提高模型的性能。其次,由于中医内容十分广泛,本研究仅把先行词分为事物和人物两类,未来还需要在此基础上进行细化,将指代消解任务精确到具体实体,以便更为精准地处理中医古籍中的指代关系。最后,本研究仅对比了3种常见模型的性能,后续当进一步拓展模型的对比研究,纳入更多不同架构、不同训练策略的模型,为中医古籍指代消解研究提供更具效能与针对性的技术支撑。

由于语料库的构建周期长、成本高,本此研究所构建的指代关系语料库将会被公开发布出来,以方便更多中医古籍研究领域的学者利用该数据进行方法学的探索。

参考文献 /Reference:

[1] 程小恩,温川飙,许强,等.基于中医药人工智能技术探讨中医药大数据的典型特征[J].世界科学技术—中医药现代化,2020,22(4):1243-1248.(CHENG X, WEN C B, XU Q et al. Development demand of artificial intelligence based on traditional Chinese medicine to study on the typical of the big data of traditional Chinese medicine[J]. Modernization of traditional Chinese medicine and materia medica-world science and technology, 2020, 22(4): 1243-1248.)

[2] ZHANG T, HUANG Z, WANG Y, et al. Information extraction from the text data on traditional Chinese medicine: a review on tasks, challenges, and methods from 2010 to 2021[J]. Evidence-based complementary and alternative medicine, 2022, 2022(14): 1-19.

[3] 孙超, 张文博. 中医古籍文本术语命名实体识别的研究进展与挑战[J]. 中华中医药杂志, 2021, 36(11): 6843-6845. (SUN C, ZHANG B W. Research progress and challenges of named entity recognition of terms in ancient Chinese medicine books[J]. China journal of traditional Chinese medicine and pharmacy, 2021, 36(11): 6843-6845.)

[4] 刘丽. 中医经方知识图谱的研究与构建[D]. 济南: 山东中医药大学, 2022. (LIU L. Study and construction of classical formula knowledge graph[D]. Jinan: Shandong University of Traditional Chinese Medicine, 2022.)

[5] 李娜. 面向方志类古籍的多类型命名实体联合自动识别模型构建[J]. 图书馆论坛, 2021, 41(12): 113-123. (LI N. Construction of automatic recognition model of multi-type named entities for local gazetteers[J]. Library tribune, 2021, 41(12): 113-123.)

[6] 曾子玲. 基于古籍的阴虚证知识图谱构建及其关键技术研究[D]. 北京: 中国中医科学院, 2022. (ZENG Z. Construction of knowledge map of yin deficiency syndrome based on ancient books and research on key technologies[D]. Beijing: China Academy of Chinese Medical Sciences, 2022.)

[7] 包振山, 宋秉彦, 张文博, 等. 基于半监督学习和规则相结合的中医古籍命名实体识别研究[J]. 中文信息学报, 2022, 36(6): 90-100. (BAO Z S, SONG B Y, ZHANG W B, et al. Named entity recognition in traditional Chinese medicine books combining semi-supervised learning and rule-based approach[J]. Journal of Chinese information processing, 2022, 36(6): 90-100.)

[8] XI W, GU P. The language of ancient Chinese medicine[J]. The Chinese journal for the history of science and technology, 2020, 41(3): 298-305.

[9] 纪晓丽, 张辉, 李爱军. 神经语言学视角下语言学热点问题研究——以《科学》杂志《语言与大脑》专刊为例[J]. 西安外国语大学学报, 2021, 29(2): 1-7. (JI X L, ZHANG H, LI A J. Research on hot linguistic issues from the perspective of neurolinguistics: taking the special issue "language and brain" of science magazine as an example[J]. Journal of Xi'an International Studies University, 2021, 29(2): 1-7.)

- [10] MASSIMO P, ROLAND S, YANNICK V. Anaphora resolution[M]. 1st ed. Berlin: Springer, 2016.
- [11] RHEA S, SOUJANYA P, ERIK C, et al. Anaphora and coreference resolution: a review[J]. Information fusion, 2020, 59(2020): 139-162.
- [12] CONVERSE S P. Developing guidelines for the annotation of anaphors in the Chinese Treebank[C]//Proceedings of the first SIGHAN workshop on Chinese language processing. Philadelphia: University of Pennsylvania, 2002: 1-7.
- [13] DODDINGTON G, MITCHELL A, PRZYBOCKI M, et al. The automatic content extraction (ace) program-tasks, data, and evaluation[C]// Proceedings of LREC. Lisbon: Researchr, 2004: 837-840.
- [14] PRADHAN S, MOSCHITTI A, XUE N, et al. CoNLL-2012 shared task: Modeling multilingual unrestricted coreference in OntoNotes[C]//Proceedings of the Joint Conference on EMNLP and CoNLL-Shared Task. Jeju Island: Association for Computational Linguistics, 2012: 1-40.
- [15] PENG Y, ZHANG Y, HUANG S, et al. Resolution of personal pronoun anaphora in Chinese micro-blog[C]//Lecture Notes in Computer Science. Cham: Springer, 2018: 592-605.
- [16] U.S. National Institute of Standards and Technology (NIST). TAC knowledge base population (KBP) 2017 [EB/OL]. [2025-05-21]. <https://tac.nist.gov/2017/KBP/>.
- [17] Chinese Language Understanding Evaluation Benchmark: datasets, baselines, pre-trained models, corpus and leaderboard [EB/OL]. [2025-05-21]. <https://www.cluebenchmarks.com/>.
- [18] LI S N, QU W G, WEI T X, et al. A survey of chinese anaphora resolution[C]//Lecture Notes in Computer Science. 7th International Conference. Dublin: Springer, 2021:180-192.
- [19] MASSIMO P, YU J T, SILVIU P, et al. Computational models of anaphora[J]. Annual review of linguistics, 2023, 9: 561-587.
- [20] 饶志强. 基于领域规则和深度学习的文本信息提取 [D]. 西安: 西安电子科技大学, 2017. (RAO Z Q. Text information extraction based on domain rules and deep learning[D]. Xi'an: Xidian University, 2017.)
- [21] JIANG F, COHN T. Incorporating syntax and semantics in coreference resolution with heterogeneous graph attention network[C]//Proceedings of the 2021 conference of the North American Chapter of the Association for Computational Linguistics: Human language technologies. Mexico City: North American Chapter of the Association for Computational Linguistics, 2021: 1584-1591.
- [22] 陈诗, 王东波, 黄水清. 数字人文下的典籍人称代词指代消解研究 [J]. 情报理论与实践, 2021, 44(10): 165-172. (CHEN S, WANG D B, HUANG S Q. Research on the resolution of personal pronoun in classical books under the digital humanism[J]. Information studies: theory & application, 2021, 44(10): 165-172.)
- [23] JOSHI M, LEVY O, WELD D S, et al. BERT for coreference resolution: baselines and analysis[EB/OL]. [2025-05-21]. <https://arxiv.org/abs/1908.09091>.
- [24] 陈雨, 玄宇航, 张玉志. 基于深度学习和指代消解的中文人名识别 [J]. 数据与计算发展前沿, 2022, 4(2): 63-73. (CHEN Y, XUAN Y H, ZHANG Y Z. Research on Chinese name recognition based on deep learning and coreference resolution[J]. Frontiers of data & computing, 2022, 4(2): 63-73.)
- [25] ALEXANDER S, TATIANA L. Knowledge fusion patterns: a survey[J]. Information fusion, 2019, 52(2019): 31-40.
- [26] ZHAO X J, JIA Y, LI A, et al. Multi-source knowledge fusion: a survey[J]. World Wide Web, 2020, 23(4): 2567-2592.
- [27] HE B, DONG B, GUAN Y er al. Building a comprehensive syntactic and semantic corpus of Chinese clinical texts[J]. Journal of biomedical informatics, 2017, 69: 203-217.
- [28] ZHOU X, PENG Y, LIU B. Text mining for traditional Chinese medical knowledge discovery: a survey[J]. Journal of biomedical informatics, 2010, 43(4): 650-660.
- [29] DING P S, PACKARD J. New Approaches to Chinese Word Formation: Morphology, Phonology, and the Lexicon in Modern and Ancient Chinese[J]. Language, 1997, 75(2): 396.
- [30] KUSUM L, PARDEEP S, KANLESH D. A comprehensive review on feature set used for anaphora resolution[J]. Artificial intelligence review, 2021, 54(4): 2917-3006.
- [31] 裘沛然. 中华医典 [CD]. 长沙: 湖南电子音像出版社, 2014. (QIU P R. Chinese medical canon[CD]. Changsha: Hunan Electronic & Audio-Video Press, 2014.)
- [32] NADKARNI P, OHNO-MACHADO L, CHAPMAN W. Natural language processing: an introduction[J]. Journal of the American Medical Informatics Association, 2011, 18(5): 544-551.
- [33] ZHANG T, WANG Y, WANG X, et al. Constructing fine-grained entity recognition corpora based on clinical records of traditional Chinese medicine[J]. BMC medical informatics and decision

making, 2020, 20(1): 1-17.

- [34] COHEN J. A coefficient of agreement for nominal scales[J]. Educational and psychological measurement, 1960, 20(1): 37-46.
- [35] TANG W, HU J, ZHANG H et al. Kappa coefficient: a popular measure of rater agreement[J]. Shanghai arch psychiatry, 2015, 27(1): 62-67.
- [36] CARLETTA J. Assessing agreement on classification tasks: the kappa statistic[J]. Computational linguistics, 1996, 22(2): 249-254.

作者贡献说明 /Author contributions:

张婷婷: 数据采集、数据标注与数据分析, 论文撰写与修改;
王亚强: 提出研究构思, 数据标注工作技术指导;
梁海峰: 标注系统维护及数据处理;
闵新: 算法模型训练、测试和评价;
杨静: 论文修改;
温川飙: 技术指导, 论文修改。

Research on Corpus Construction and Reference Resolution Methods of Ancient Literature on Traditional Chinese Medicine*

Zhang Tingting^{1,2} Wang Yaqiang³ Liang Haifeng³ Min Xin⁴ Yang Jing² Wen Chuanbiao⁴

¹School of Chinese Classics, Chengdu University of Traditional Chinese Medicine, Chengdu 610075

²Digital Key Laboratory for the Protection and Research of Unearthed Medical Literature and Cultural Relics, Key Laboratory of Philosophy and Social Sciences in Sichuan Province, Chengdu 610075

³School of Software Engineering, Chengdu University of Information Technology, Chengdu 610225

⁴School of Intelligent Medicine, Chengdu University of Traditional Chinese Medicine, Chengdu 610075

Abstract: [Purpose/Significance] The reference resolution is one of the key steps to acquire knowledge and construct the knowledge map of ancient books. However, there is a lack of published corpora of referential relations of ancient TCM literature, which makes it difficult to carry out the research of reference resolution. Based on this, this study takes ancient literature on stroke and abdominal pain during pregnancy as examples, constructs a corpus of referential relations, and conducts experiments on reference resolution methods to provide references for the following research. **[Method/Process]** This paper selected ancient literature records of stroke and pregnancy abdominal pain from the “Chinese Medical Code”, defined and annotated three types of pronouns, two types of antecedents and one type of referential relations, and constructed a corpus through manual annotation and evaluated its quality. In the experimental stage, the reference resolution task was divided into two subtasks: referent recognition and referential relations prediction. The experimental group selected the reference resolution model BERT-BiLSTM-CRF based on the pre-trained model BERT, and compared it with the BiLSTM-CRF and CRF models. **[Result/Conclusion]** The average score of corpus inter-annotator agreement (IAA) is 0.87, suggesting that the corpus quality is good. The BERT-BiLSTM-CRF model is significantly better than the other two models in the reference resolution task. In general, it is feasible to use deep learning technology to perform the reference resolution of ancient TCM literature, and the pre-trained model BERT can improve the model performance. Future research will need to further increase the scale of the corpus and train large language models to help the research of knowledge discovery on ancient TCM literature.

Keywords: ancient TCM literature corpus reference relation reference resolution

*This work is supported by the “Xinglin Scholar” Disciplinary Talent Promotion Program Project of Chengdu University of Traditional Chinese Medicine, titled “Research on the Construction and Application of the Knowledge Graph of Ancient Chinese Medicine Literature Based on Semantic Analysis: Taking Apoplexy as an Example” (Grant No. BSH2020031); and the special project commissioned by the Research Center for Unearthed Medical Literature and Cultural Relics in China, titled “Digital Excavation and Analysis of Unearthed Medical Cultural Relics” (Grant No. ctwx2424).

Author(s): Zhang Tingting, lecturer, PhD; Wang Yaqiang, professor, PhD; Liang Haifeng, master candidate; Min Xin, lecturer, PhD; Yang Jing, professor, master’s degree; Wen Chuanbiao, professor, master’s degree, corresponding author, E-mail: wcb@cduetcm.edu.cn.

Received: 2024-08-02 Revised: 2024-12-07 Pages: 113-120